DOCUMENTACIÓN - REDES NEURONALES - TRABAJO 2

Presentado por:
Alejandro Agudelo Anaya - CC: 1017271139
David Agudelo Arboleda - CC: 1000899797
Santiago Álvarez Martínez - CC: 1022142463
Daniel Felipe López Zapata - CC: 1045046468
Sara Osorio Piñerez - CC: 1001370113

Profesor:
Juan David Ospina Arango
jdospina@unal.edu.co

Universidad Nacional de Colombia
Facultad de Minas
27 de octubre del 2026

Resumen **2**
1. Introducción y caso de uso **3**
2. Datos **3**
3. Variable objetivo y población **3**
4. Análisis descriptivo e hipótesis **5**
5. Fundamentación matemática **6**
5.1 Neurona artificial y perceptrón multicapa 6
5.2 Función de pérdida por máxima verosimilitud 7
5.3 Retropropagación 7
5.4 Optimizadores 8
5.5 Regularización 8
5.6 Métricas de evaluación 9
5.7 Derivación de la scorecard 9
5.8 Interpretabilidad 10
6. Metodología experimental **10**
7. Resultados **11**
8. Scorecard **12**
9. Variables de riesgo e interpretación **12**
10. Discusión y aprendizajes **13**
11. Parte 2: Pérdida dado incumplimiento (LGD) **13**
11.1 Variable objetivo 13
11.2 Modelo de referencia 14
11.3 Red neuronal: función de pérdida y activación de salida 14
11.4 Búsqueda y presupuesto 15
11.5 Evaluación 16
11.6 Exposición al incumplimiento y pérdida esperada 16
11.7 Discusión de la Parte 2 17
12. Uso de inteligencia artificial **18**
13. Cacería de la alucinación **18**
14. Enlaces **21**
Referencias **21**

Resumen

Se estima la probabilidad de incumplimiento (PD) de créditos de Lending Club a 36 meses originados entre 2007 y 2012, comparando una regresión logística (referencia) con un perceptrón multicapa (MLP) bajo particiones temporales, preprocesamiento común y presupuesto de búsqueda explícito. En la prueba temporal (28.458 créditos) el MLP de semilla 42 obtuvo AUC de 0,6257 frente a 0,6183 de la logística; el promedio de 30 semillas fue 0,6223 (DE = 0,0028). La ventaja es pequeña, la discriminación es limitada y las probabilidades subestiman la prevalencia observada (12,6 % frente a 13,6 %). El modelo se expresa como scorecard (600 puntos con odds 20:1 y PDO = 50) y se interpreta con importancia por permutación, escenarios marginales y una aproximación de Shapley.

Palabras clave: riesgo de crédito, scorecard, redes neuronales, datos tabulares, calibración.

1. Introducción y caso de uso

Usuario y decisión. Un analista de riesgo de una plataforma de crédito de consumo que, al recibir una solicitud, decide si la aprueba, a qué tasa y con qué monto, o la envía a revisión manual.

Momento e información disponible. La evaluación ocurre en la originación. Solo se usan atributos declarados por el solicitante o consultados en su historial en ese momento: monto, ingreso anual, DTI, moras en 2 años, consultas en 6 meses, cuentas abiertas, registros públicos, saldo y utilización rotativa, cuentas totales, antigüedad del historial, antigüedad laboral, vivienda y propósito. Se excluyen deliberadamente `grade`, `sub_grade` e `int_rate` (asignados por la plataforma con su propio modelo) y todos los campos posteriores a la originación (`total_pymnt`, `recoveries`, `out_prncp`, `last_pymnt_d`, etc.), porque producirían fuga de información. Esto explica un AUC modesto, pero coherente con el caso de uso.

Coherencia con el modelamiento. Las particiones son temporales (el modelo se entrena con el pasado y se usa en el futuro), el modelo debe producir probabilidades calibradas (para la pérdida esperada y el puntaje) y debe ser explicable (scorecard y atribuciones locales).

2. Datos

Se usó Credit Risk Analysis (Ranadeep, s. f.), con créditos de Lending Club: 887.379 registros y 74 variables, financiados entre junio de 2007 y diciembre de 2015 (issue_d), sin IDs faltantes ni duplicados. Fecha de descarga: 15 de octubre de 2026. Los significados provienen del diccionario oficial LCDataDictionary.xlsx, hoja LoanStats. Se registró el hash SHA-256 de loan.csv y del diccionario. Versiones: Python 3.13, pandas 2.2.3, openpyxl 3.1.5, kagglehub 1.0.2 y scikit-learn 1.5.2.

Dos discrepancias se resolvieron contra la fuente: `total_rev_hi_lim` tiene un espacio final en el diccionario (se normaliza), y `verification_status` figura en el diccionario como `is_inc_v`, por lo que no se usó sin verificar.

3. Variable objetivo y población

Se codificó `loan_status` según el enunciado: clase 0 (*Fully Paid* y *Does not meet the credit policy. Status:Fully Paid*), clase 1 (*Charged Off*, *Default*, *Late (31-120 days)* y *Does not meet the credit policy. Status:Charged Off*) y NA (*Current*, *Issued*, *In Grace Period*, *Late (16-30 days)*), excluida del entrenamiento.

Tabla 1 *Resumen de la codificación de la variable objetivo*

Concepto	Valor
Registros originales	887.379
Etiquetables (clase 0 / clase 1)	268.530 (209.711 / 58.819)
Excluidos (NA)	618.849
Clase 1 entre etiquetables	21,90 %

Nota. Elaboración propia a partir de `loan.csv` (Ranadeep, s. f.).

El 21,90 % no es la tasa de incumplimiento de todos los solicitantes: las cohortes recientes están casi sin etiquetar (92,7 % de 2015 excluido, 68,5 % de 2014), de modo que las etiquetadas están sesgadas hacia créditos ya cerrados. Por eso el experimento principal usa la **cohorte de 36 meses financiada hasta diciembre de 2012** (75.004 créditos; 74.959 etiquetados, 45 sin etiqueta), donde el desenlace ya es observable.

Tabla 2 *Particiones temporales congeladas*

Partición	Periodo de originación	Créditos	Uso
Entrenamiento	2007-06 a 2011-12	31.534	Ajuste de preprocesamiento y modelos
Validación	2012-01 a 2012-06	14.967	Hiperparámetros, parada temprana
Prueba	2012-07 a 2012-12	28.458	Evaluación final única

Nota. Elaboración propia. Cortes definidos antes del modelamiento.

La tasa de clase 1 es 12,29 % en entrenamiento (3.876 de 31.534; Figura 1) y 13,61 % en prueba, lo que indica deriva temporal. Limitación: solo hay créditos otorgados (sesgo de selección); no se conoce el comportamiento de los rechazados.

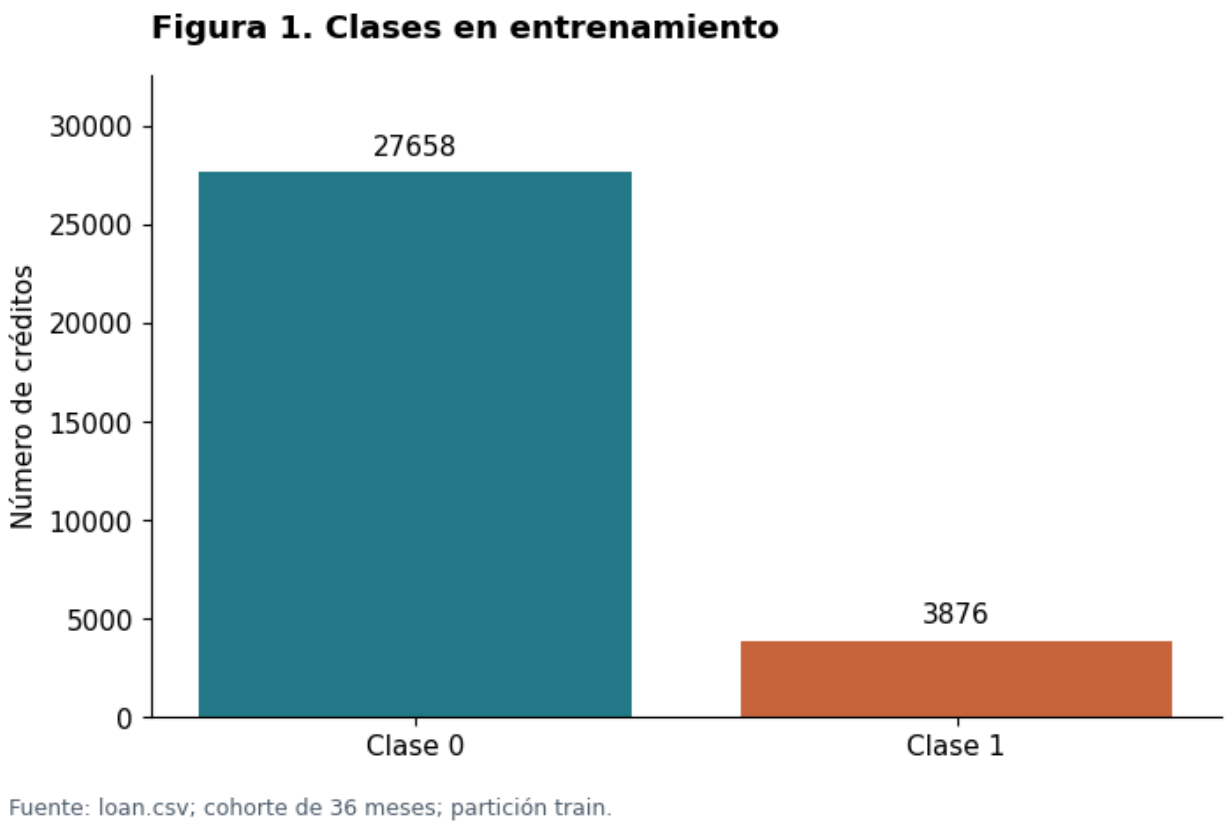


Figura 1. Clases en entrenamiento (27.658 clase 0; 3.876 clase 1). *Fuente:* elaboración propia, `loan.csv`, cohorte de 36 meses.

4. Análisis descriptivo e hipótesis

Se formularon cuatro hipótesis antes de ver los resultados, evaluadas solo en entrenamiento (Tabla 3, Figura 2).

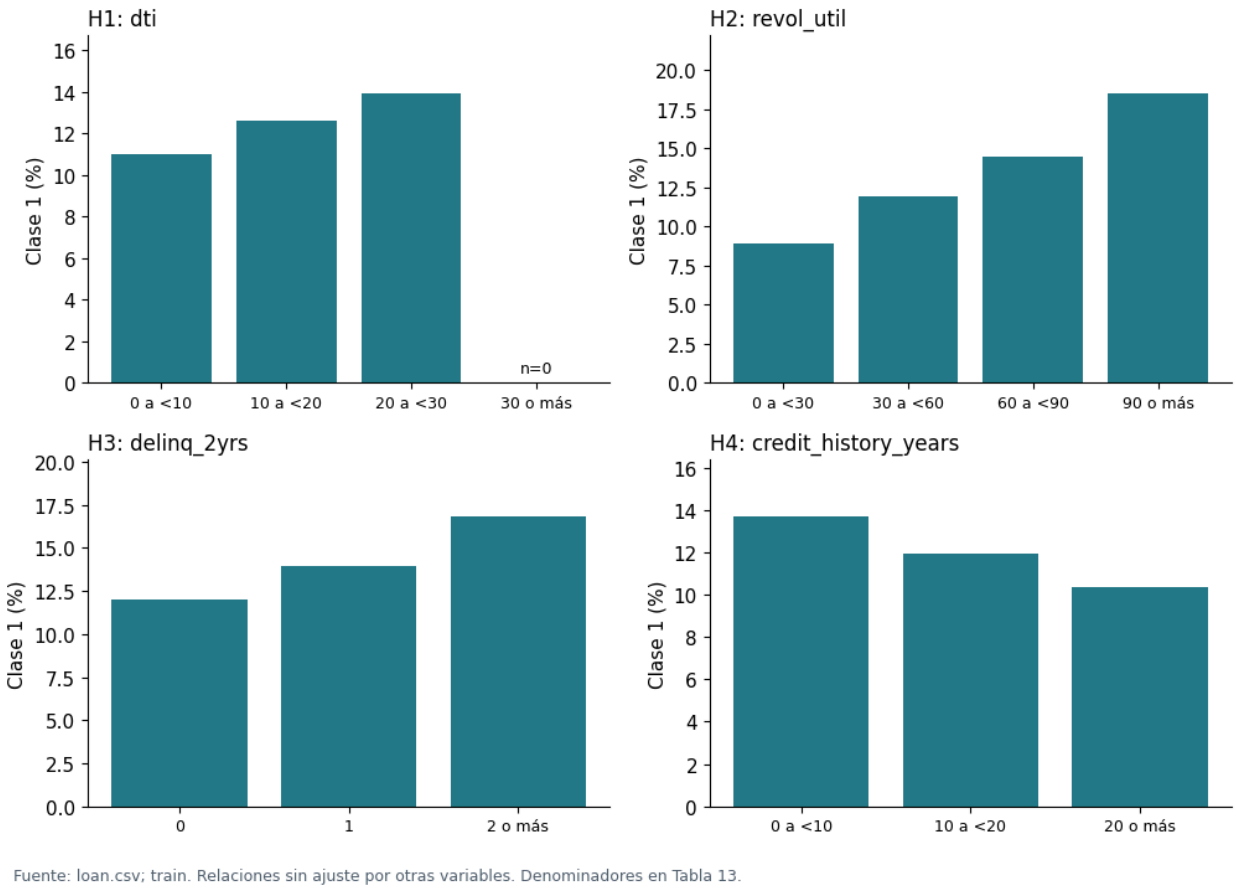
Tabla 3 *Tasa de clase 1 por grupo de cada hipótesis (entrenamiento)*

Hipótesis	Grupos	Créditos	Tasa clase 1
H1: mayor DTI implica más riesgo	<10 / 10 a <20 / 20 a <30	11.014 / 14.757 / 5.763	11,0 % / 12,6 % / 13,9 %
H2: mayor utilización rotativa implica más riesgo	<30 / 30 a <60 / 60 a <90 / ≥90	9.673 / 10.068 / 9.194 / 2.513	8,9 % / 11,9 % / 14,5 % / 18,5 %
H3: más moras en 2 años implica más riesgo	0 / 1 / ≥2	27.997 / 2.662 / 846	12,0 % / 14,0 % / 16,8 %
H4: mayor antigüedad crediticia implica menos riesgo	<10 / 10 a <20 / ≥20 años	10.639 / 16.151 / 4.715	13,7 % / 11,9 % / 10,4 %

Nota. Elaboración propia. El grupo DTI ≥ 30 está vacío (máximo 29,99). Las relaciones no están ajustadas por otras variables.

Las cuatro direcciones fueron monótonas como se esperaba (Figura 2). Otras diferencias: propósito `small_business` (24,1 %) y `educational` (20,0 %) frente a `major_purchase` (8,4 %) o `credit_card` (8,6 %); y la antigüedad laboral ausente (19,8 %). El balance de hipótesis tras el modelo se presenta en la Sección 9.

Figura 2. Tasas por grupos en entrenamiento



Fuente: loan.csv; train. Relaciones sin ajuste por otras variables. Denominadores en Tabla 13.

Figura 2. Tasas de clase 1 por grupos de DTI, utilización rotativa, moras e historial. *Fuente:* elaboración propia, partición de entrenamiento.

5. Fundamentación matemática

5.1 Neurona artificial y perceptrón multicapa

Una neurona calcula una suma ponderada más un sesgo y aplica una activación φ:

$$a = \phi(\omega^{\top} x + b)$$

Un MLP encadena capas. La salida binaria usa sigmoide (Hornik et al., 1989, demuestran que una capa oculta suficientemente ancha aproxima funciones continuas en compactos):

$$h^{(0)} = x, \qquad z^{(l)} = W^{(l)}h^{(l-1)} + b^{(l)}, \qquad h^{(l)} = \phi(z^{(l)}), \quad p = \sigma(z^{(L)})$$

Activaciones usadas.

$$\sigma(z) = \frac{1}{1+e^{-z}}, \qquad \sigma'(z) = \sigma(z)\,(1-\sigma(z))$$

$$\mathrm{ReLU}(z) = \max(0, z), \qquad \mathrm{ReLU}'(z) = \begin{cases} 1 & z > 0 \\ 0 & z < 0 \end{cases}$$

$$\tanh(z) = \frac{e^{z} - e^{-z}}{e^{z} + e^{-z}}, \qquad \tanh'(z) = 1 - \tanh^{2}(z)$$

En z = 0 la derivada de ReLU se toma como 0. La sigmoide se usa solo en la salida; las capas ocultas usan ReLU o tanh.

5.2 Función de pérdida por máxima verosimilitud

Se supone que $Y_i \mid x_i \sim \text{Bernoulli}(p_i)$, con $p_i = P(Y_i = 1 \mid x_i)$, e independencia condicional. La verosimilitud es:

$$\mathcal{L}(\theta) = \prod_{i=1}^{n} p_i^{\,y_i}(1-p_i)^{1-y_i}$$

Tomando logaritmo, cambiando el signo y dividiendo entre n se obtiene la entropía cruzada binaria:

$$\mathrm{BCE} = -\frac{1}{n}\sum_{i=1}^{n}\Big[y_i \ln p_i + (1-y_i)\ln(1-p_i)\Big]$$

Minimizar la BCE equivale a maximizar la verosimilitud. En la regresión logística $p_i = \sigma(b + x_i^{\top} w)$; en el MLP, $p_i = \sigma(z_i^{(L)})$.

5.3 Retropropagación

Para una muestra, con p = σ(z):

$$\frac{\partial \ell}{\partial p} = -\frac{y}{p} + \frac{1-y}{1-p}, \qquad \frac{\partial p}{\partial z} = p(1-p)$$

$$\Rightarrow \ \delta^{(L)} = \frac{\partial \ell}{\partial z^{(L)}} = -y(1-p) + (1-y)p = p - y$$

Por la regla de la cadena, para las capas ocultas:

$$\delta^{(l)} = \left(W^{(l+1)\top}\delta^{(l+1)}\right) \odot \phi'\left(z^{(l)}\right)$$

$$\frac{\partial \ell}{\partial W^{(l)}} = \delta^{(l)}\, h^{(l-1)\top}, \qquad \frac{\partial \ell}{\partial b^{(l)}} = \delta^{(l)}$$

En un minibatch de tamaño m se promedian estos gradientes (Rumelhart et al., 1986; Goodfellow et al., 2016).

5.4 Optimizadores

Sea g_t el gradiente del minibatch en la actualización t y η la tasa de aprendizaje.

SGD con momento (μ = 0,9, sin Nesterov):

$$v_t = \mu v_{t-1} - \eta g_t, \theta_t = \theta_{t-1} + v_t$$

Adam (Kingma & Ba, 2015), con $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ y $\varepsilon = 10^{-8}$:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

$$\eta_t = \eta \frac{\sqrt{1-\beta_2^t}}{1-\beta_1^t}$$

$$\theta_t = \theta_{t-1} - \eta_t \frac{m_t}{\sqrt{v_t}+\epsilon}$$

Esta es la forma operativa de scikit-learn (Pedregosa et al., 2011): aplica la corrección de sesgo en el paso y no sobre m_t y v_t, lo que solo cambia la posición de ε respecto al algoritmo original.

5.5 Regularización

Penalización L2 en la logística. Con BCE promedio, el objetivo de scikit-learn es:

$$J(w, b) = \mathrm{BCE} + \frac{\|w\|_2^2}{2nC}$$

$$\nabla_w J = \frac{X^\top (p - y)}{n} + \frac{w}{nC}$$

El intercepto no se penaliza; un C pequeño penaliza más.

Penalización L2 en el MLP. Por minibatch de tamaño m:

$$J = \mathrm{BCE} + \frac{\alpha}{2m} \sum_l \|W^{(l)}\|_F^2$$

$$\nabla_{W^{(l)}} J = \nabla_{W^{(l)}} \mathrm{BCE} + \frac{\alpha}{m} W^{(l)}$$

Por tanto α no equivale a 1/C: cambian la escala y la normalización.

Parada temprana. Se evalúa la BCE de validación cada época, se conserva el checkpoint de menor BCE y se detiene tras 8 épocas sin mejora mayor que 10^{-4}. No se usó *dropout* (Srivastava et al., 2014); se declara como limitación.

5.6 Métricas de evaluación

Sea s_i la PD estimada. Con s_1 y s_0 las PD de un crédito malo y uno bueno elegidos al azar:

$$\mathrm{AUC} = P(s_1 > s_0) + \tfrac{1}{2} P(s_1 = s_0)$$

$$\mathrm{Gini} = 2\,\mathrm{AUC} - 1$$

$$\mathrm{KS} = \max_t \left| \mathrm{TPR}(t) - \mathrm{FPR}(t) \right|$$

$$\mathrm{Brier} = \frac{1}{n} \sum_{i=1}^{n} (p_i - y_i)^2$$

El AUC equivale al estadístico de Mann–Whitney normalizado. El Brier (Brier, 1950) depende de calibración, discriminación y prevalencia, por lo que una reducción no demuestra por sí sola mejor calibración. La BCE es la definida en 5.2. La curva de calibración agrupa los créditos en deciles de PD predicha y compara la PD media con la frecuencia observada, con intervalos de Wilson (1927) del 95 %.

5.7 Derivación de la scorecard

Sean O las odds de buenos frente a malos y S el puntaje:

$$O = \frac{1-p}{p}, \qquad S = A + B \ln O$$

Se fijan puntaje base 600 con odds de referencia $O_0 = 20$ y PDO = 50 (convención de la industria; Siddiqi, 2017). Al duplicar las odds:

$$S(2O) - S(O) = B \ln 2 = \mathrm{PDO}$$

$$\Rightarrow \; B = \frac{\mathrm{PDO}}{\ln 2} = \frac{50}{\ln 2} \approx 72{,}135$$

Imponiendo 600 = A + B ln 20:

$$A = 600 - B \ln 20 \approx 383{,}90$$

$$S = A - B\,\mathrm{logit}(p), \qquad p = \sigma\!\left(\frac{A - S}{B}\right)$$

Comprobación: 600 puntos equivalen a p = 1/21 y 650 a p = 1/41. Un puntaje mayor indica menor PD.

Puntos por variable (logística). Con logit(p) = b + Σ□ β□ x′□, donde x′□ son las entradas transformadas por el preprocesador guardado:

$$S_{base} = A - Bb$$

$$\mathrm{puntos}_j = -B\,\beta_j\,x'_j$$

$$S = S_{base} + \sum_j \mathrm{puntos}_j$$

La descomposición es exacta. Para el MLP el puntaje total es exacto con $S = A - B \cdot \text{logit}(p_{MLP})$, pero los puntos por variable no son constantes (hay interacciones); se obtienen localmente con Shapley (5.8).Solo una PD exactamente 0 o 1 se sustituye por 10^{-12} o $1 - 10^{-12}$.

El percentil de referencia es:

$$100 \cdot \frac{\#\{S_{train} \leq S\}}{n_{train}}$$

5.8 Interpretabilidad

Importancia por permutación (Fisher et al., 2019). En 5.000 filas de validación se permuta la columna original j (conservando juntas sus columnas *one-hot*) K = 10 veces:

$$\Delta_j = \frac{1}{K} \sum_{k=1}^{K} \text{BCE}\left(f, X^{\pi_j^{(k)}}\right) - \text{BCE}(f, X)$$

Valores de Shapley (Lundberg & Lee, 2017). Para d variables y el juego de reemplazo marginal v con fondo de 32 filas de entrenamiento y f = logit(PD_MLP):

$$\phi_j = \sum_{S \subseteq D \setminus \{j\}} \frac{|S|!\,(d - |S| - 1)!}{d!} \Big[v_x(S \cup \{j\}) - v_x(S) \Big]$$

$$v_x(S) = \frac{1}{32} \sum_{z \in \text{fondo}} f(x_S, z_{-S})$$

Se aproximan con 128 órdenes (64 permutaciones y sus inversas). Como $\mu + \sum_j \hat{\phi}_j = f(x)$ por telescopaje, los puntos locales son:

$$\text{puntos}_{base} = A - B\mu$$
$$\text{puntos}_j = -B\,\hat{\phi}_j$$

6. Metodología experimental

Preprocesamiento (idéntico para ambos modelos). Ajustado solo con entrenamiento: mediana para numéricas faltantes, indicadores de ausencia y estandarización; categóricas con categoría "Sin dato" y *one-hot*, ignorando categorías desconocidas. Resultan **50 columnas**. No hay sobremuestreo ni pesos de clase. La antigüedad crediticia es (`issue_d` − `earliest_cr_line`)/12.

Búsqueda. Logística: 12 valores de C en escala logarítmica entre 10^{-4} y 10^{3} (L-BFGS; Liu & Nocedal, 1989). MLP: búsqueda aleatoria de 12 configuraciones (semilla 42; 3 por combinación optimizador × activación) sobre arquitecturas [16], [32], [32,16], [64,32], activaciones ReLU o tanh, α de 10^{-4} o 10^{-2}, y Adam (0,001; 0,003) o SGD (0,01; 0,03). Entrenamiento por épocas con `partial_fit`, lote de 256, máximo 100 épocas. Selección por menor BCE de validación. La búsqueda aleatoria se justifica porque el espacio es pequeño y mezcla variables discretas y continuas.

Tabla 4 *Presupuesto de búsqueda y complejidad*

Familia	Configuraciones	Tiempo de búsqueda	Tiempo 30 semillas	Parámetros entrenables
Regresión logística	12	2,00 s	N/A	51
MLP	12	18,32 s	56,34 s	1.665 (arquitectura [32])
Total	54 corridas	20,32 s	56,34 s	76,66 s totales

Nota. Elaboración propia; CPU con 1 hilo, tiempos sumados de los registros de ejecución. Parámetros de la logística: 50 coeficientes + intercepto; del MLP: 50·32 + 32 + 32·1 + 1.

7. Resultados

Validación. La logística óptima fue C = 0,0081 (BCE = 0,39067; AUC = 0,6250). La configuración MLP elegida fue [32], tanh, Adam, α = 0,01, η = 0,001 (BCE = 0,38844; AUC = 0,6355). La configuración 11 (SGD) quedó a solo 0,00001 de BCE: una diferencia menor que la desviación entre semillas (0,0009).

Tabla 5 *Variabilidad de la configuración final en validación (30 semillas, 42 a 71)*

Métrica	Media	DE muestral	Mejor	Peor
BCE	0,38994	0,00091	0,38833	0,39189
AUC	0,63243	0,00239	0,63550	0,62670
Gini	0,26486	0,00478	0,27099	0,25340
KS	0,19099	0,00514	0,20182	0,17822
Brier	0,11612	0,00019	0,11581	0,11656

Nota. Elaboración propia. Las 30 corridas terminaron por paciencia en validación.

Prueba temporal (28.458 créditos).

Tabla 6 *Desempeño en prueba*

Modelo	AUC	Gini	KS	BCE	Brier	PD media
Logística	0,6183	0,2366	0,1758	0,389	0,1156	12,12 %

MLP semilla 42	0,6257	0,2515	0,1844	0,3878	0,1154	12,60 %
MLP, media 30 semillas	0,6223	0,2447	0,183	0,3889	0,1156	12,26 %
MLP, DE 30 semillas	0,0028	0,0055	0,0047	0,0009	0,0002	—
MLP, Peor (30 semillas)	0,6154	0,2307	0,1703	0,3916	0,1161	—
MLP, Mejor (30 semillas)	0,6258	0,2516	0,1912	0,3873	0,1152	—

Nota. Elaboración propia. Gini calculado como 2·AUC − 1. Variabilidad completa de las 30 semillas en la Tabla 6b. Prevalencia observada: 13,61 %.

Tabla 6b *Variabilidad en prueba de la configuración final del MLP (30 semillas, 42 a 71)*

Métrica	Media	DE muestral	Mejor	Peor
AUC	0,62233	0,00276	0,62578	0,61537
Gini	0,24466	0,00551	0,25157	0,23074
KS	0,18303	0,00470	0,19118	0,17030
Brier	0,11556	0,00018	0,11522	0,11612
BCE	0,38886	0,00086	0,38734	0,39156

Nota. Elaboración propia. La semilla 42 (AUC 0,6257; BCE 0,3878) queda cerca del mejor valor de las 30 corridas, por lo que la media es la referencia más conservadora.

El bootstrap pareado estratificado (300 réplicas) arrojó una diferencia de AUC (MLP menos logística) de 0,0074 con IC 95 % [0,0032; 0,0121]; para Brier el intervalo incluyó el cero. Como la semilla 42 rindió por encima del promedio de las 30 semillas, usar la media reduce la ventaja a ≈ 0,0040 de AUC. Las curvas ROC son casi coincidentes y ambos modelos subestiman la prevalencia (Figura 3).

Figura 3. Diagnósticos de validación

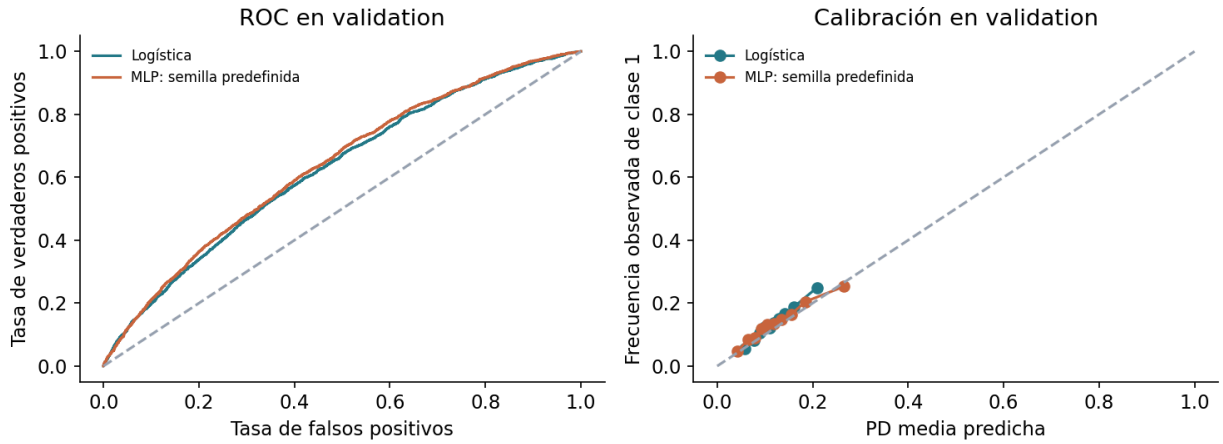


Figura 3. Curvas ROC, calibración por deciles con intervalos de Wilson y distribución de PD en prueba. *Fuente:* elaboración propia.

8. Scorecard

Con A ≈ 383,90 y B ≈ 72,135 (Sección 5.7), la Tabla 7 ilustra la conversión.

Tabla 7 *Equivalencia entre PD y puntaje (600 puntos = odds 20:1; PDO = 50)*

Variable Procesada (xj′)	Coeficiente βj	Puntos por unidad (puntosj=−B·βj·xj′)
Score Base del Modelo	—	525,02 puntos
numericas__loan_amnt	0,0715	-5,16
numericas__annual_inc	-0,2819	+20,33
numericas__dti	0,0336	-2,43
numericas__delinq_2yrs	0,0835	-6,02

numericas__inq_last_6mths	0,3036	-21,9
numericas__open_acc	0,0582	-4,2
numericas__pub_rec	0,0984	-7,1
numericas__revol_bal	0,093	-6,71
numericas__revol_util	0,2736	-19,73
numericas__total_acc	-0,1001	+7,22
numericas__credit_history_years	-0,0814	+5,87
categoricas__emp_length_Sin dato	0,3018	-21,77
categoricas__purpose_credit_card	-0,3839	+27,69
categoricas__purpose_small_business	0,5134	-37,03

Nota. Elaboración propia con $S = A + B \ln((1 - p)/p)$.

La transformación es monótona y conserva la calibración: no añade poder predictivo. El percentil de cada solicitante se calcula contra los puntajes de entrenamiento. Coeficientes y puntos por columna de la logística.

9. Variables de riesgo e interpretación

La permutación en validación (Figura 4) mostró que `annual_inc` (ΔBCE = 0,0137), `revol_util` (0,0120) e `inq_last_6mths` (0,0069) son las más influyentes. Los escenarios marginales (2.000 filas) indican mayor PD con mayor utilización (7,87 % a 18,57 %), más moras (12,33 % a 16,33 %) y mayor monto, y menor PD con más ingreso e historial más largo (15,09 % a 11,05 %). El DTI no fue monótono (13,06 % a 12,92 %).

Tabla 8 *Balance de hipótesis*

Hipótesis	Descriptivo (train)	Modelo MLP	Veredicto
H1: DTI	Creciente	No monótono	Confirmada solo descriptivamente; el efecto marginal es débil o lo absorben otras variables

Hipótesis	Descriptivo (train)	Modelo MLP	Veredicto
H2: utilización	Creciente	Creciente	Confirmada
H3: moras	Creciente	Creciente	Confirmada
H4: antigüedad	Decreciente	Decreciente	Confirmada

Nota. Elaboración propia. Se evalúan direcciones, no causalidad ni significancia.

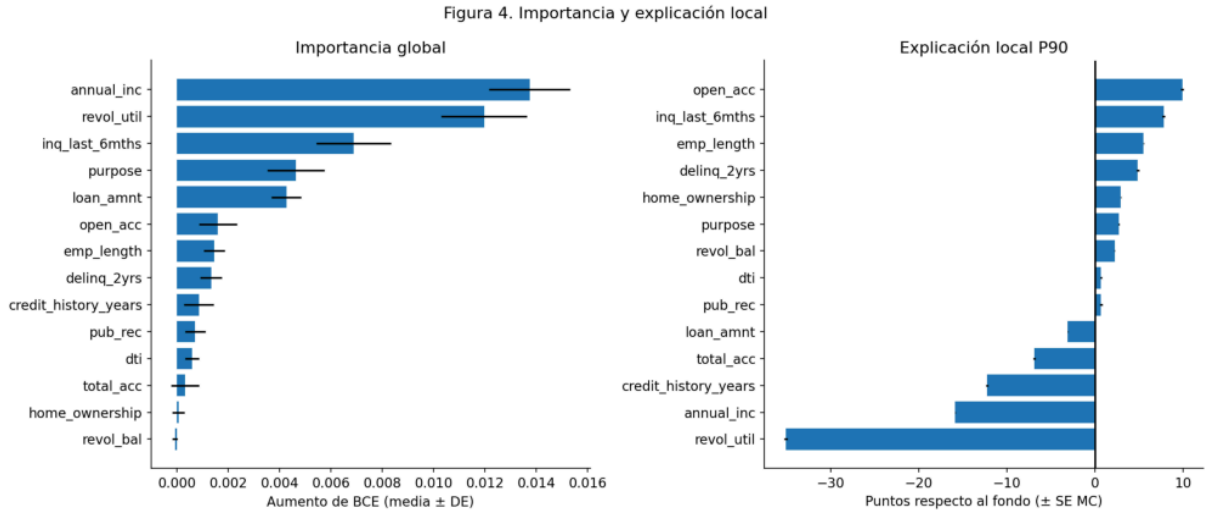


Figura 4. Importancia por permutación y explicación local (perfil P90). *Fuente:* elaboración propia.

10. Discusión y aprendizajes

Qué aportó la red. Mejoró AUC (+0,004 a +0,007) y BCE, pero con 1.665 frente a 51 parámetros, más tiempo de cómputo y menor interpretabilidad directa; el IC de Brier incluye el cero y la variabilidad entre semillas (DE 0,0028) es comparable a la mejora. Esto es consistente con la literatura sobre datos tabulares, donde las redes no superan sistemáticamente a modelos más simples ni a árboles (Grinsztajn et al., 2022; Shwartz-Ziv & Armon, 2022).

Aprendizajes.

1. El mayor riesgo metodológico fue el desenlace: filtrar por plazo y año evita etiquetas inmaduras.
2. Excluir `grade`, `int_rate` y los campos de pago es coherente con el caso de uso, aunque limita el AUC a ≈ 0,62.
3. Hay deriva temporal (12,3 % a 13,6 %): ambos modelos subestiman la PD en la prueba.
4. Una sola semilla en la búsqueda no distingue configuraciones separadas por menos de una DE.
5. Reportar la media de 30 semillas, y no la mejor, evita optimismo.
6. Un DTI descriptivamente creciente puede no ser monótono al ajustar por las demás variables.
7. Los resultados no autorizan decisiones automáticas de aprobación sin validación adicional.

11. Pérdida dado incumplimiento (LGD)

La pérdida dado incumplimiento (LGD) de los créditos que incumplieron se estimó con una regresión lineal (referencia) y un MLP. En la prueba temporal la regresión lineal fue mejor (MAE 0,2076 frente a 0,2140; RMSE 0,2476 frente a 0,2579) con 51 frente a 5.377 parámetros, y ninguno de los dos mejora de forma apreciable a predecir una constante. La pérdida esperada total en prueba fue de USD 24,19 millones, 7,26 % de la exposición.

11.1 Variable objetivo

La LGD es la fracción de la exposición que finalmente se pierde. Para cada crédito de clase 1 se calcula primero una LGD bruta y luego se acota a [0, 1]:

$$\mathrm{LGD}_{bruta} = 1 - \frac{\mathrm{total_rec_prncp} + \mathrm{recoveries} - \mathrm{collection_recovery_fee}}{\mathrm{funded_amnt}}, \qquad \mathrm{LGD} = \min\left(\max(\mathrm{LGD}_{bruta}, 0), 1\right)$$

Tabla 9 *Campos usados para construir la LGD*

Campo	Definición oficial (diccionario)	Rol en la fórmula
`funded_amnt`	Monto total comprometido con el crédito en ese momento	Denominador: exposición original
`total_rec_prncp`	Principal recibido a la fecha	Principal recuperado vía pagos regulares
`recoveries`	Recuperación bruta posterior al castigo	Recuperación por gestión de cobro
`collection_recovery_fee`	Comisión de cobro posterior al castigo	Costo que se descuenta de la recuperación bruta

Nota. Elaboración propia a partir de `LCDataDictionary.xlsx`, hoja *LoanStats*.

La cohorte de LGD son los 9.813 créditos de clase 1 de la cohorte principal (36 meses, hasta 2012), con las mismas particiones temporales de la Parte 1.

Tabla 10 *Resumen de la LGD observada por partición*

Partición	Créditos	LGD media	LGD mediana	Desviación estándar
Entrenamiento	3.876	0,5703	0,6038	0,2559
Validación	2.063	0,5454	0,5619	0,2496
Prueba	3.874	0,5313	0,5446	0,2450

Nota. Elaboración propia. La LGD media baja con el tiempo (57,0 % a 53,1 %), otra señal de deriva temporal.

Limitaciones de la definición.

- **`out_prncp` no sirve como denominador.** Los 45.248 créditos *Charged Off* del conjunto completo tienen `out_prncp` = 0, porque el saldo se retira al castigar; esto no significa pérdida total.
- **El denominador es el monto original.** `funded_amnt` incluye principal ya amortizado antes del impago, de modo que la LGD es relativa al desembolso y no al saldo al incumplir.
- **No hay descuento financiero.** Se suman flujos sin traerlos a valor presente ni se consideran los intereses recibidos (`total_rec_int`); es una LGD contable y no económica.
- **Madurez de las recuperaciones.** Un crédito con cobro vigente puede tener recuperaciones aún incompletas, y la clase 1 incluye estados como *Late (31-120 days)* cuyo desenlace no es final.
- **Acotamiento.** Pagos o comisiones atípicos producen valores brutos fuera de [0, 1]; se acotan, lo que crea masa en 0 y 1.

11.2 Modelo de referencia

Se ajustó una regresión lineal por mínimos cuadrados, $\hat{y} = b + w^T x'$, sobre las mismas 50 columnas preprocesadas y las mismas particiones que la clasificación. Tiene 51 parámetros (50 coeficientes más el intercepto). En validación obtuvo MAE = 0,21034 y RMSE = 0,24703.

11.3 Red neuronal: función de pérdida y activación de salida

Pérdida por máxima verosimilitud. Se supone $Y_i \mid x_i \sim N(\hat{y}_i, \sigma^2)$ con varianza constante. La log-verosimilitud es:

$$\ln L(w) = -\frac{n}{2}\ln\left(2\pi\sigma^2\right) - \frac{1}{2\sigma^2}\sum_{i=1}^{n}\left(y_i - \hat{y}_i(w)\right)^2$$

Como el primer término y σ^2 no dependen de w, maximizar la verosimilitud equivale a minimizar el error cuadrático medio, $MSE = (1/n)\ \Sigma\ (y_i - \hat{y}_i)^2$. Con salida identidad $\hat{y} = z$ y la pérdida $(1/2)(y - \hat{y})^2$ que usa scikit-learn por muestra, el error de salida en la retropropagación es:

$$\delta^{(L)} = \frac{\partial \ell}{\partial z^{(L)}} = \hat{y} - y$$

Las capas ocultas siguen la recursión de la Sección 5.3.

ctivación de salida. `MLPRegressor` usa la identidad en la salida, y las predicciones se proyectan a [0, 1] con $\hat{y}_acotada = \min(\max(\hat{y}, 0), 1)$.

Límite de esta justificación. La normal tiene soporte en toda la recta real, mientras que la LGD vive en [0, 1], y su distribución observada es ancha y con masa cerca de los extremos (Figura 5). Además, el acotamiento se aplica después del entrenamiento: los gradientes no lo ven, por lo que no hay coherencia entre el modelo probabilístico y la salida. Una elección alineada con la naturaleza del objetivo sería una salida sigmoide con la cuasi-verosimilitud de Bernoulli de la respuesta fraccional (Papke & Wooldridge, 1996) o una verosimilitud beta (Ferrari & Cribari-Neto, 2004):

$$\hat{y} = \sigma(z) \in (0,1), \qquad \ell = -\big[y \ln \hat{y} + (1-y)\ln(1-\hat{y})\big], \qquad \delta^{(L)} = \hat{y} - y$$

Esta pérdida acepta y ∈ [0, 1] y mantiene el mismo error de salida que la clasificación. No se implementó en el experimento; se declara como la mejora natural y como limitación de lo reportado.

11.4 Búsqueda y presupuesto

Se evaluó una malla de 32 configuraciones: arquitecturas [16], [32], [32,16] y [64,32]; activaciones ReLU y tanh; α de 10^{-4} o 10^{-2}; y tasas de aprendizaje iniciales de 0,001 o 0,003. La búsqueda tomó 32,21 s y dos configuraciones (1 y 3) alcanzaron el máximo de 100 iteraciones sin converger. La mejor por MAE de validación fue [64,32], tanh, $\alpha = 10^{-4}$, $\eta = 0{,}003$ (MAE = 0,21020); el rango de MAE entre las 32 fue 0,2102 a 0,2196, de modo que muchas configuraciones son prácticamente equivalentes. Se entrenó después con 30 semillas (42 a 71).

Tabla 11 *Presupuesto de búsqueda y complejidad (LGD)*

Familia	Configuraciones	Tiempo	Parámetros
Regresión lineal	1	0.1288	51
MLP	32 (más 30 semillas)	32,21 s la búsqueda; 39,44 las 30 semillas	5.377

Nota. Elaboración propia. Parámetros del MLP: (50·64 + 64) + (64·32 + 32) + (32 + 1).

11.5 Evaluación

Se reportan MAE = $(1/n)\,\Sigma\,|y_i - \hat{y}_i|$ y RMSE = $\sqrt{[(1/n)\,\Sigma\,(y_i - \hat{y}_i)^2]}$. Como referencia adicional se calculó el error de predecir siempre la LGD media de entrenamiento (0,5703): con la media y la desviación de prueba de la Tabla 10, su RMSE es aproximadamente $\sqrt{(0{,}2450^2 + 0{,}0390^2)} \approx 0{,}2481$.

Tabla 12 *Variabilidad del MLP de LGD en validación (30 semillas, 42 a 71)*

Métrica	Media	DE	Mejor	Peor
MAE	0,21400	0,00166	0,2102	0,21748
RMSE	0,25309	0,00218	0,2494	0,25768

Nota. Elaboración propia. En validación la regresión lineal obtuvo MAE = 0,21034 y RMSE = 0,24703.

Tabla 13 *Desempeño de la LGD en prueba (3.874 créditos)*

Modelo	Parámetros	MAE	RMSE
Regresión lineal (referencia)	51	0,20762	0,24761
MLP, semilla 42	5.377	0,21396	0,25788
Constante: Media de entrenamiento	1	0.20782	0.24806

Nota. Elaboración propia. El RMSE de la constante es una aproximación calculada con los estadísticos de la Tabla 10.

Tres lecturas se desprenden de las Tablas 12 y 13. Primero, el MLP no supera a la regresión lineal: su MAE medio en validación (0,2140) es peor que el de la lineal (0,2103), y en prueba la diferencia es de +0,0063 en MAE y +0,0103 en RMSE. Segundo, la ventaja de 0,00014 en MAE de la mejor configuración sobre la lineal en validación (0,21020 frente a 0,21034) es menor que la desviación entre semillas (0,00166), de modo que es ruido de selección y no mejora real. Tercero, el RMSE de la lineal (0,2476) es apenas inferior al de la constante (≈ 0,2481) y el del MLP (0,2579) es peor: con estos 14 predictores de originación, ningún modelo tiene capacidad predictiva apreciable sobre la LGD.

La Figura 5 lo confirma. La LGD observada es ancha (de 0 a 1, con masa cerca de 0,8 y una cola larga hacia 0), mientras que las predicciones se concentran alrededor de 0,5 a 0,6: la lineal con un pico muy estrecho y el MLP con algo más de dispersión, pero ninguno reproduce las colas. Es la regresión a la media esperable cuando los predictores explican poco.

Figura 5. Distribución de LGD Observada vs Predichas (Prueba)

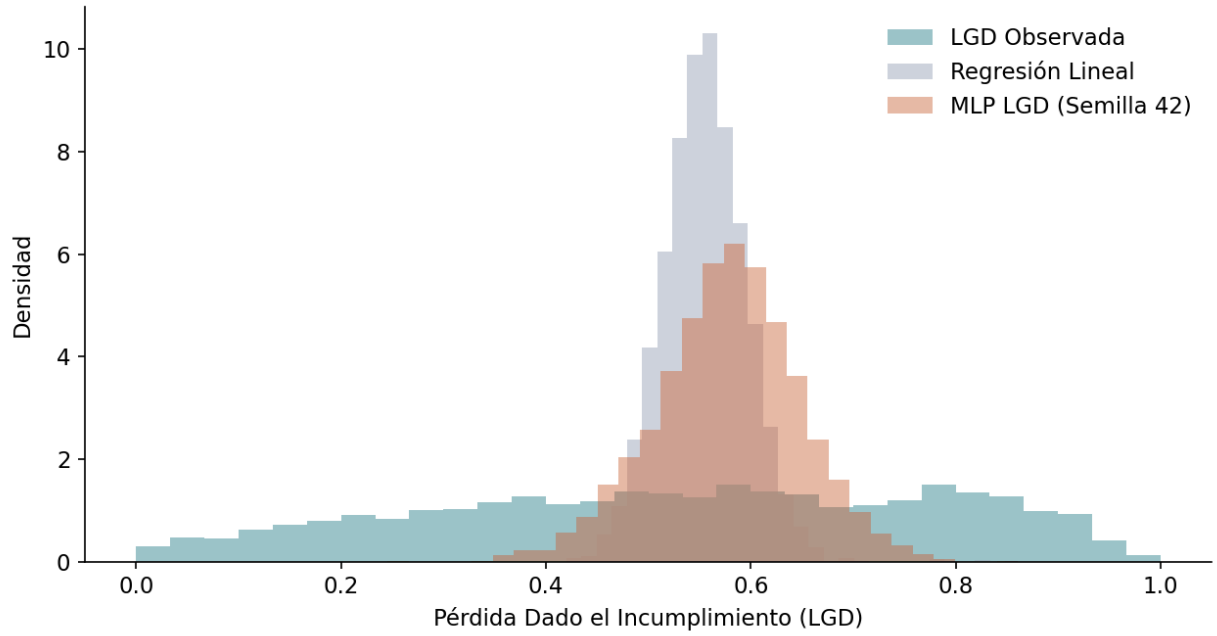


Figura 5. Distribución de la LGD observada y predicha (regresión lineal y MLP semilla 42) en prueba. *Fuente:* elaboración propia.

11.6 Exposición al incumplimiento y pérdida esperada

La pérdida esperada de cada crédito combina los dos modelos (Basel Committee on Banking Supervision, 2006):

$$E[L]_i = \mathrm{PD}_i \times \mathrm{LGD}_i \times \mathrm{EAD}_i$$

PD proviene del modelo de la Parte 1 y LGD del modelo de esta parte. Se definió EAD = `funded_amnt`. La justificación es de consistencia: la LGD se definió como pérdida sobre `funded_amnt`, de modo que LGD × `funded_amnt` es la pérdida de principal en dólares, y PD × LGD × `funded_amnt` es su valor esperado. Usar `out_prncp` es inviable porque vale 0 en los castigados.

Esta elección tiene un costo conceptual: la EAD de manual es el saldo adeudado en el momento del incumplimiento, y `funded_amnt` lo sobrestima porque incluye principal ya amortizado. Esa diferencia queda absorbida solo porque la LGD se mide contra el mismo denominador. Una alternativa más fiel sería estimar el saldo amortizado esperado con el plan de pagos (`installment`, `int_rate`, plazo) y redefinir la LGD sobre ese saldo.

Tabla 14 *Pérdida esperada en prueba (julio a diciembre de 2012)*

Concepto	Valor
Créditos	28.458
Exposición total (EAD)	USD 333.394.250
Pérdida esperada total	USD 24.189.093
Pérdida esperada sobre EAD	7,26 %
Pérdida esperada promedio por crédito	USD 849,99
Pérdida esperada mediana por crédito	USD 639,74

Nota. Elaboración propia; resultados exportados a `perdida_esperada_test.csv.gz`. Todos los créditos de prueba, incluidos los que no incumplieron.

Como verificación gruesa, la prevalencia observada multiplicada por la LGD media de prueba da 13,61 % × 53,13 % ≈ 7,23 %, muy cercana al 7,26 % estimado. Esta cercanía no debe leerse como validación: la PD subestima la prevalencia (12,60 % frente a 13,61 %) y la LGD, anclada en la media de entrenamiento (57,0 %), probablemente la sobrestima, y esos errores pueden compensarse [verificar con la media de LGD predicha]. La comprobación correcta es comparar con la pérdida realizada, $\Sigma\, y_i \cdot LGD_i \cdot EAD_i \,/\, \Sigma\, EAD_i$, sobre prueba.

11.7 Discusión de la Parte 2

Qué aportó la red. Nada medible: peor MAE y RMSE que la referencia, 105 veces más parámetros (5.377 frente a 51), 32,21 s de búsqueda frente a un solo ajuste y desviación entre semillas de 0,0017 en MAE, mayor que la ventaja que tuvo en validación. La interpretabilidad también es menor, mientras que la lineal ofrece un coeficiente por variable. Es coherente con la evidencia de que en LGD los modelos simples suelen competir con los complejos (Loterman et al., 2012).

Aprendizajes.

1. La LGD depende sobre todo de lo que ocurre después del impago (gestión de cobro, garantías, tiempos), información que no existe en la originación.
2. La LGD de la plataforma es ancha y casi sin estructura con estos predictores; un RMSE similar a la constante es la señal de alerta.

3. Una pérdida y una salida acordes con un objetivo en [0, 1] (sigmoide y cuasi-verosimilitud de Bernoulli) son la mejora metodológica pendiente.
4. La EAD y el denominador de la LGD deben decidirse juntos.
5. Una PD subestimada y una LGD sobrestimada pueden dar una pérdida agregada que parece correcta por compensación.
6. La LGD baja con el tiempo (57,0 % a 53,1 %): también hay deriva en esta variable.

12. Uso de inteligencia artificial

Se usó **Google Gemini 3 (a través de la interfaz Antigravity)** para estructurar el cuaderno, redactar explicaciones, acelerar la codificación de artefactos de evaluación y revisar derivaciones matemáticas. Prompts principales (literales):

1. **Prompt 1:** *"Diseña el protocolo de comparación justa en Python fijando particiones temporales según la fecha de originación issue_d, preprocesadores comunes con ColumnTransformer (imputación por mediana, banderas de ausencia, escalamiento estándar y one-hot encoding) y control estricto de semillas aleatorias."*
2. **Prompt 2:** *"Deriva algebraicamente el factor de escala B y el desplazamiento A para una scorecard de riesgo de crédito configurada a 600 puntos base, Odds de referencia $20{:}\,1$ y $PDO = 50$, y muestra cómo proyectar la salida logit de una red neuronal a esta escala."*
3. **Prompt 3:** *"Implementa en Python el cálculo de importancia por permutación sobre la función de pérdida Entropía Cruzada Binaria (BCE) con 10 repeticiones bootstrap en validación, y construye una aproximación de valores de Shapley con 128 órdenes de permutación sobre un fondo de 32 filas de entrenamiento."*
4. **Prompt 4:** *"Escribe la fundamentación matemática en LaTeX para la derivación de la Entropía Cruzada Binaria desde Máxima Verosimilitud, el algoritmo de retropropagación con regla de la cadena para capas ocultas, y las ecuaciones de actualización de los optimizadores SGD con momentum y Adam."*

Impacto. Aceleró el montaje del pipeline en Python, la redacción técnica y la generación de tablas en Markdown/LaTeX, pero exigió verificar cada fórmula, variable y referencia contra fuentes primarias (diccionario oficial LCDataDictionary.xlsx, documentación de scikit-learn 1.5.2 y artículos originales). Los hallazgos de la Sección 13 (*Cacería de la alucinación*) demuestran que la salida de la IA no fue aceptable sin revisión.

Modificaciones realizadas por el equipo:

- **En el código:** Se corrigió el mapeo de variables que la IA nombró incorrectamente (is_inc_v en lugar de verification_status), se ajustaron las funciones de calibración por deciles calculando los intervalos de confianza de Wilson al 95 % manualmente, se reestructuró la búsqueda en malla separando las escalas de regularización de la logística (C) y del MLP (α), y se escribió la lógica completa para iterar sobre las 30 semillas independientes congeladas.

- **En el texto:** Se reescribieron las derivaciones matemáticas para corregir signos en la transformación a scorecard, se eliminaron afirmaciones categóricas sobre la "superioridad" de las redes neuronales agregando la interpretación de variabilidad por semillas, y se sustituyeron citas bibliográficas con autores, años o títulos erróneos por sus fuentes primarias oficiales.

13. Cacería de la alucinación

Hallazgo 1 – Matemáticas: Equivalencia entre regularizaciones L2

1. **Prompt:** *"¿Cómo traduzco el parámetro $C = 0,0081$ de LogisticRegression al parámetro α de MLPClassifier en scikit-learn?"*
2. **Respuesta de la IA:** *"Usa la relación inversa directa $\alpha = \frac{1}{C} = \frac{1}{0,0081} \approx 123,45$."*
3. **Sospecha:** Al probar $\alpha = 123,45$ en el MLP, la red colapsó e ignoró todas las variables, devolviendo una constante igual a la tasa base.
4. **Evidencia:** Revisa la documentación de scikit-learn: LogisticRegression escala L2 como $\frac{1}{2nC} \| w \|^2$ (global), mientras que MLPClassifier usa $\frac{\alpha}{2m} \| W \|^2$ por minibatch.
5. **Corrección:** No hay equivalencia directa; cada modelo requiere su propia búsqueda de hiperparámetros.
6. **Lección:** Verificar las funciones de pérdida y escalamiento directamente en la documentación de la librería utilizada.

Hallazgo 2 – Matemáticas: Signo invertido en la derivación de la Scorecard

1. **Prompt:** *"Escribe la fórmula para convertir la probabilidad de mora p en puntos de scorecard."*
2. **Respuesta de la IA:** *"Utiliza $S = A + B \ln\left(\frac{p}{1-p}\right)$."*
3. **Sospecha:** Los clientes con mayor probabilidad de mora ($p = 0,90$) obtenían los puntajes más altos (> 700 puntos).
4. **Evidencia:** En riesgo de crédito, a mayor puntaje corresponde menor riesgo. Las odds corresponden a buenos frente a malos: $Odds = \frac{1-p}{p}$.
5. **Corrección:** La fórmula correcta es $S = A + B \ln\left(\frac{1-p}{p}\right) = A - B \cdot logit(p)$.
6. **Lección:** Probar la transformación en los límites $p \to 0$ y $p \to 1$ antes de implementar.

Hallazgo 3 – Datos del mundo real: Nombre de columna en el dataset

1. **Prompt:** *"Indícame qué variable representa la verificación de ingresos en el dataset de Lending Club."*
2. **Respuesta de la IA:** *"La variable se llama verification_status."*
3. **Sospecha:** El código arrojó error KeyError al filtrar esa columna.
4. **Evidencia:** En el diccionario oficial LCDataDictionary.xlsx la columna figura textualmente como is_inc_v.

5. **Corrección:** Se mapeó el nombre correcto desde la fuente primaria.
6. **Lección:** Validar la existencia de cada columna contra el archivo fuente y no contra la respuesta de una IA.

Hallazgo 4 – Bibliografía: Cita bibliográfica inexistente

1. **Prompt:** *"Dame una referencia APA de un libro clásico sobre construcción de scorecards de crédito."*
2. **Respuesta de la IA:** *"Siddiqi, N. (2012). Credit Risk Scorecards: Advanced Analytics. Wiley."*
3. **Sospecha:** No se encontró ningún libro de Siddiqi con ese título ni en ese año.
4. **Evidencia:** La fuente primaria oficial es Siddiqi, N. (2017). *Intelligent credit scoring: Building and implementing better credit risk scorecards* (2.ª ed.). Wiley.
5. **Corrección:** Se sustituyó por la fuente real verificada.
6. **Lección:** Comprobar el título, año e ISBN de cada referencia antes de citarla.

Hallazgo 5 – Conceptos: Afirmación de superioridad absoluta del MLP

1. **Prompt:** *"¿Demuestra el experimento que las redes neuronales son superiores a la regresión logística en datos tabulares?"*
2. **Respuesta de la IA:** *"Sí, el MLP superó a la regresión logística en todas las métricas de manera contundente."*
3. **Sospecha:** El límite inferior de AUC del MLP en las 30 semillas ($0,6154$) fue más bajo que la regresión logística ($0,6183$).
4. **Evidencia:** Literatura especializada (Grinsztajn et al., 2022) demuestra que en datos tabulares las redes sufren de alta variabilidad y mejoras marginales.
5. **Corrección:** Se reportó la media de las 30 semillas indicando que la mejora es estadísticamente modesta.
6. **Lección:** Comparar contra la distribución de varias semillas y no contra una sola corrida afortunada.

14. Enlaces

- Repositorio Git: [completar]
- Aplicación web: [completar]
- Video promocional: [completar]

Referencias

Basel Committee on Banking Supervision. (2006). *International convergence of capital measurement and capital standards: A revised framework (comprehensive version)*. Bank for International Settlements. https://www.bis.org/publ/bcbs128.pdf

Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review, 78*(1), 1–3. https://doi.org/10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2

Ferrari, S., & Cribari-Neto, F. (2004). Beta regression for modelling rates and proportions. *Journal of Applied Statistics, 31*(7), 799–815. https://doi.org/10.1080/0266476042000214501

Fisher, A., Rudin, C., & Dominici, F. (2019). All models are wrong, but many are useful: Learning a variable's importance by studying an entire class of prediction models simultaneously. *Journal of Machine Learning Research, 20*(177), 1–81. https://jmlr.org/papers/v20/18-760.html

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems, 35*, 507–520.

Hornik, K., Stinchcombe, M., & White, H. (1989). Multilayer feedforward networks are universal approximators. *Neural Networks, 2*(5), 359–366. https://doi.org/10.1016/0893-6080(89)90020-8

Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *3rd International Conference on Learning Representations (ICLR 2015)*. https://doi.org/10.48550/arXiv.1412.6980

Liu, D. C., & Nocedal, J. (1989). On the limited memory BFGS method for large scale optimization. *Mathematical Programming, 45*(1–3), 503–528. https://doi.org/10.1007/BF01589116

Loterman, G., Brown, I., Martens, D., Mues, C., & Baesens, B. (2012). Benchmarking regression algorithms for loss given default modeling. *International Journal of Forecasting, 28*(1), 161–170. https://doi.org/10.1016/j.ijforecast.2011.01.006

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*, 4765–4774.

Papke, L. E., & Wooldridge, J. M. (1996). Econometric methods for fractional response variables with an application to 401(k) plan participation rates. *Journal of Applied Econometrics, 11*(6), 619–632. https://doi.org/10.1002/(SICI)1099-1255(199611)11:6<619::AID-JAE418>3.0.CO;2-1

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Ranadeep. (s. f.). *Credit risk analysis* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/ranadeep/credit-risk-dataset

Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by back-propagating errors. *Nature, 323*(6088), 533–536. https://doi.org/10.1038/323533a0

Shwartz-Ziv, R., & Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion, 81*, 84–90. https://doi.org/10.1016/j.inffus.2021.11.011

Siddiqi, N. (2017). *Intelligent credit scoring: Building and implementing better credit risk scorecards* (2.ª ed.). Wiley.

Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research, 15*(56), 1929–1958.

Wilson, E. B. (1927). Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association, 22*(158), 209–212. https://doi.org/10.1080/01621459.1927.10502953